CNNs interpretables para clasificar Alzheimer en resonancia magnética estructural

Tecnológico de Monterrey · GenoBit

Abstract

La enfermedad de Alzheimer (EA) es un trastorno neurodegenerativo progresivo sin cura, y el tratamiento iniciado en etapas tempranas puede frenar su avance [1]. La resonancia magnética (RM) estructural muestra la pérdida de tejido cerebral que acompaña a la enfermedad. Proponemos clasificar la EA en RM de la base pública OASIS-1 con una arquitectura híbrida CNN–transformer, interpretable mediante mapas de atención, y separando los datos por sujeto para evitar la fuga de información que infla muchos resultados previos [2].

Introducción

La EA comienza a nivel celular: la beta-amiloide se acumula en placas fuera de las neuronas y la proteína tau forma ovillos dentro de ellas, seguidos de neurodegeneración, es decir, pérdida de sinapsis y neuronas [3]. Esta pérdida no es uniforme: los ovillos aparecen primero en la región entorrinal, luego llegan al hipocampo y solo después se extienden por la neocorteza [4].

El estado cognitivo se ordena en un continuo: **CN** (cognitivamente normal), **MCI** (deterioro cognitivo leve) y **AD** (demencia por EA). Los estudios de clasificación usan estas etapas como etiquetas, aunque el estado cognitivo por sí solo no confirma la EA biológica [3].

Estado del arte

Las CNN dominan la clasificación de EA con neuroimagen, pero muchos estudios dividen los datos por imagen y no por sujeto, lo que sobreestima la exactitud [2]. Estudios que sí separan por sujeto:

Paper	Hallazgo	Exactitud
Ebrahimi et al. (2021) [5]	ResNet-18 + red convolucional temporal sobre los cortes (ADNI, 450 sujetos)	**91.78 %** AD vs CN
Kong et al. (2022) [6]	CNN 3D sobre RM y PET fusionadas (ADNI, 370 sujetos)	**93.21 %** AD vs CN
Zhao et al. (2024) [7]	ResNet-50 3D con ideas de transformers (ADNI, 818 sujetos)	**92.14 %** CN/MCI/AD

CNNs y transformers

El deep learning usa redes de muchas capas que aprenden las características directamente de los datos, en vez de medidas diseñadas a mano como el volumen de una región.

Una CNN aplica filtros pequeños (p. ej., 3×3×3) que detectan patrones locales, desde bordes hasta estructuras más grandes [8]. Un transformer usa auto-atención para relacionar todas las regiones del volumen entre sí, y sus pesos de atención se pueden visualizar como mapas que muestran en qué se fija el modelo.

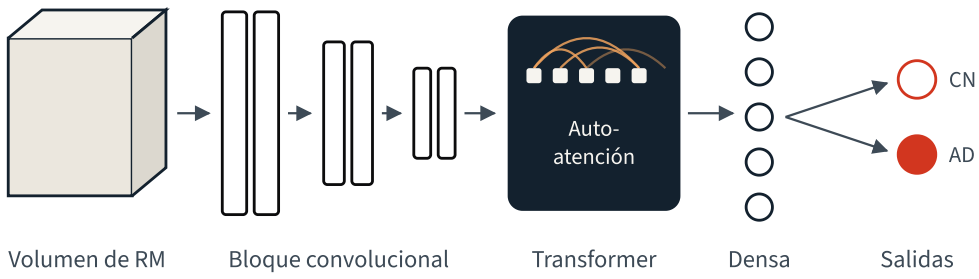


Figura 1. Arquitectura híbrida propuesta: el bloque convolucional extrae características locales del volumen, el transformer las relaciona entre sí con auto-atención y la capa densa da la probabilidad de CN y de AD.

Cerebro sano vs. Alzheimer

En la RM ponderada en T1, sustancia gris, sustancia blanca y líquido cefalorraquídeo tienen intensidades distintas, así que la pérdida de tejido se ve como estructuras más pequeñas y espacios de líquido más grandes [9].

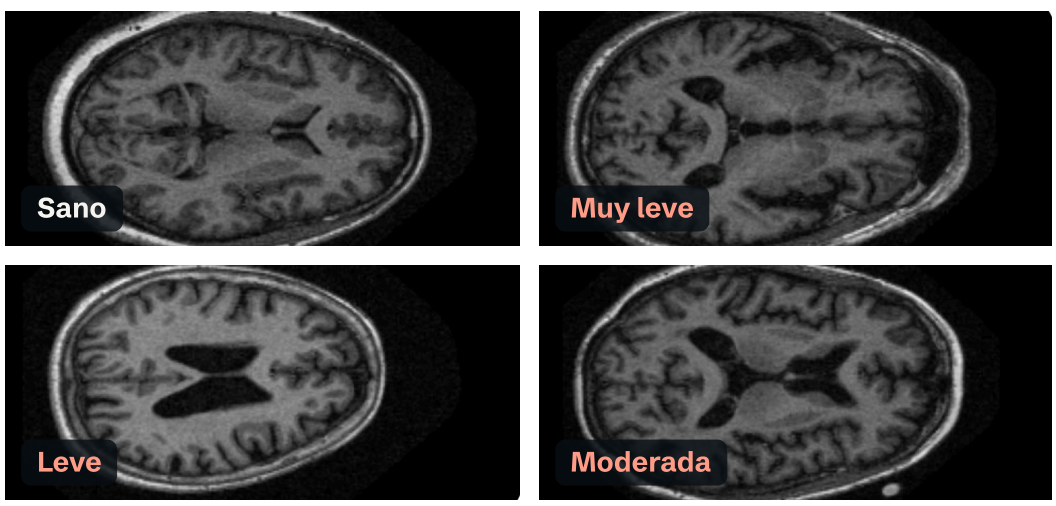


Figura 2. Cortes axiales de RM en T1 según la severidad. Con la EA, los surcos se ensanchan y los ventrículos se agrandan por la pérdida de tejido.

Metodología

Datos
RM estructural de la base pública OASIS-1.

↓

Preprocesamiento
Reducción de ruido, registro y extracción del cráneo.

↓

División por sujeto
Ningún sujeto aparece en más de un conjunto.

↓

Modelo híbrido CNN–transformer
Convoluciones + auto-atención para distinguir CN de AD.

↓

Interpretabilidad
Mapas de atención sobre las regiones que guían la decisión.

Referencias

[1] Nibila y Sivagami (2026). *Front. Artif. Intell.*
[2] Wen et al. (2020). *Med. Image Anal.*
[3] Jack et al. (2018). *Alzheimer's & Dementia.*
[4] Braak y Braak (1991). *Acta Neuropathol.*
[5] Ebrahimi et al. (2021). *Comput. Biol. Med.*
[6] Kong et al. (2022). *Biomed. Signal Process. Control.*
[7] Zhao et al. (2024). *Front. Neurol.*
[8] Prince (2023). *Understanding Deep Learning*. MIT Press.
[9] Frisoni et al. (2010). *Nat. Rev. Neurol.*

GenoBit
Genomics and Bioinformatics

Tecnológico de Monterrey
LiFE | Grupos Estudiantiles